

Dipartimento di Matematica e Informatica Corso di Big Data a.a. 2022/2023

Introduzione pratica a Spark

Dott. Roberto Grasso

Informazioni utili



E-mail: roberto.grasso@phd.unict.it



Repository del corso:

https://github.com/RobertoGrasso96/LaboratorioBigDataUniCT



Overview

- Da MapReduce a Spark
- Resilient Distributed Dataset (RDD)
- Persistenza e Caching
- DataFrame
- Metodi di partizionamento
- Machine Learning Library (MLlib)





- Nel corso di queste lezioni useremo Python e la libreria PySpark. Ovviamente siete liberi di utilizzare il linguaggio che preferite (Java, Scala o R).
- Non è necessario installare Spark sui vostri computer! Nel materiale del corso troverete tutto il necessario per configurare l'ambiente di lavoro in maniera totalmente containerizzata.
 - Per chi volesse installare Spark: https://spark.apache.org/downloads.html
- Tutto ciò che ci servirà sarà Docker e un editor. Il mio suggerimento è di usare Visual Studio Code. Il motivo? Visual Studio Code offre un buon supporto per Python, i container Docker e i Jupyter Notebook.





Docker:

https://www.docker.com/



Visual Studio Code:

https://code.visualstudio.com/



- Per avviare i container basta lanciare (dalla root del progetto) il seguente comando: docker compose up -d
- Per arrestarli: docker compose stop
- È possibile aumentare il numero di worker, ad esempio a 3, avviando i container con il seguente comando:

 docker compose up -d --scale spark-worker=3
- Spark Web UI: http://localhost:8080/



Spark Web UI



Spark Master at spark://b4a7eb6afb4b:7077

URL: spark://b4a7eb6afb4b:7077

Alive Workers: 3

Cores in use: 3 Total, 0 Used

Memory in use: 3.0 GiB Total, 0.0 B Used

Resources in use:

Applications: 0 Running, 0 Completed

Drivers: 0 Running, 0 Completed

Status: ALIVE

→ Workers (3)

Worker Id	Address		Cores	Memory	Resources
worker-20230407144904-172.18.0.2-32985	172.18.0.2:32985	ALIVE	1 (0 Used)	1024.0 MiB (0.0 B Used)	
worker-20230407144905-172.18.0.5-36985	172.18.0.5:36985	ALIVE	1 (0 Used)	1024.0 MiB (0.0 B Used)	
worker-20230407144905-172.18.0.6-43741	172.18.0.6:43741	ALIVE	1 (0 Used)	1024.0 MiB (0.0 B Used)	

▼ Running Applications (0)

Ap	pplication ID	Name	Cores	Memory per Executor	Resources Per Executor	Submitted Time	User	State	Duration	
----	---------------	------	-------	---------------------	------------------------	----------------	------	-------	----------	--


→ Completed Applications (0)

Application ID	Name	Cores	Memory per Executor	Resources Per Executor	Submitted Time	User	State	Duration

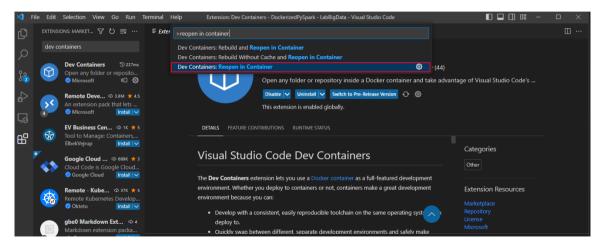
Dopo aver avviato Spark, occupiamoci del container per lo sviluppo. Aprite il progetto su Visual Studio Code e installate la seguente estensione:



Aprite la command palette:



Digitate reopen in container



Alla prima apertura verrano installate e configurate in automatico tutte le estesioni che ci serviranno.

A questo punto abbiamo tutti gli strumenti necessari per poter lavorare!



Link Utili



Documentazione PySpark

URL: https://spark.apache.org/docs/latest/api/python/



QuickStart: DataFrame

 $URL: \ https://spark.apache.org/docs/latest/api/python/getting_started/quickstart_df.html$



Machine Learning Library in PySpark (DataFrame-based)

URL: https://spark.apache.org/docs/latest/api/python/reference/pyspark.ml.html



Guida MLlib

URL: https://spark.apache.org/docs/latest/ml-guide.html

